

딥러닝 개념 정리 (2부: SSL·Transfer·Anomaly Detection)

┃ 버스 복습용. 이번 세션에서 나온 개념어 총정리.

1. 핵심 계층 구조 (제일 중요)

학습 방식 (독립 차원)	구조 (같은 레벨)	기반 알고리즘
└ 지도학습	└ MLP	└ 역전파
└ SSL(자기지도) ×	└ CNN	위에 얹힘 (모든 구조에 공통)
└ 강화학습	└ Attention	
	└ RNN	

조합 예시:

SSL + MLP = VIME

SSL + Attention = SAINT, NPT-AD

지도학습 + Attention = FT-Transformer

- 역전파 ⊂ Attention ⊂ (구조 레벨): 역전파가 가장 기본, 모든 구조 안에 포함
- MLP = Attention = CNN = RNN: 같은 레벨(구조), 서로 대등
- SSL vs 지도학습: 구조와 무관한 "학습 방식" 차원

2. SSL (Self-Supervised Learning, 자기지도학습)

정의: 레이블 없이 데이터 자체가 정답 역할을 하는 학습

지도학습: $x + y$ (사람이 만든 정답)
SSL: x 만 있음 → 원본 데이터가 스스로 정답 제공

작동 3단계

1. Pretext task (가짜 문제) 만들기 — 데이터 일부 가리기
2. Encoder 사전학습 — 가짜 문제 풀면서 표현 학습
3. Fine-tuning — 적은 레이블로 최종 작업 맞춤

핵심: 가짜 문제를 푸는 게 목적이 아니라, 그 과정에서 얻는 **부산물(데이터 구조 이해)**이 진짜 가치

언제 쓰나: 레이블 적음 + unlabeled 데이터 많을 때. 레이블 충분하면 그냥 지도학습이 나음

3. SSL 방법들 (발전 순서대로)

방법	오염/뷰 생성 방식	학습 방식	핵심 한계
VIME (2020)	다른 행 값으로 대체	Reconstruction + Mask Estimation	비현실적 샘플
SCARF (2022)	그 피처의 분포에서 샘플링	Contrastive (InfoNCE)	여전히 입력 건드림
SubTab (2021)	컬럼 부분집합으로 나눔	Reconstruction + Contrastive	중요 피처 손실 위험
SAINT (2021)	CutMix + Mixup	Contrastive + Denoising	복잡함
RaTab (2025)	가중치(W)를 SVD로 변형	Reconstruction + Contrastive	복잡한 수학
T-JEPA (2025)	입력 안 건드림, 임베딩 예측	임베딩 공간에서 예측	Collapse 취약

무엇을 건드리나 (오염 대상의 진화)

입력 공간: VIME, SCARF, SubTab, SAINT(CutMix)

임베딩 공간: SAINT(Mixup)

가중치 공간: RaTab ← 입출력 근거 없이 가중치 변형(역전파와 다른 원리)

임베딩 예측: T-JEPA ← 가장 깨끗, 입력 무손실

4. 방법별 용어 상세

VIME = Value Imputation and Mask Estimation

- Masking = 값을 그럴듯한 가짜로 바꿈(0으로 안 가림) → 어디가 오염됐는지 찾기 어렵게
- 두 task: 값 복원(Value imputation) + 오염 위치 찾기(Mask estimation)

SCARF = Self-supervised Contrastive learning using Random Feature corruption

- marginal distribution(주변 분포) = 그 피처 자체의 분포에서 값 샘플링
- 원본 + 손상본 = Positive pair

SubTab: 컬럼을 부분집합으로 나눔 = "피처 마스킹"(값 가리기가 아니라 컬럼 자체 제거)

SAINT (2가지 정체성)

- 구조: Intersample Attention (= NPT의 Datapoint Attention, 행끼리)
- 학습: CutMix(real space, 피처 덩어리 교체) + Mixup(latent space, 임베딩 혼합)

RaTab: SVD(특이값 분해)로 가중치 $W = U \times \Sigma \times V^T$ 분해 → 작은 특이값 잘라냄(Truncated) → 살짝 다른 Encoder → 다른 뷰

T-JEPA: Context 피쳐 임베딩으로 Target 피쳐 임베딩 예측 (SubTab은 피쳐 자르기, T-JEPA는 임베딩 자르기 → 정보 손실 없음)

5. Reconstruction vs Contrastive (SSL 두 축)

Reconstruction (복원):

"망가진 값 → 원래 값 복원"

→ 피쳐 하나하나 정확한 값 관계 학습 (세밀)

→ VIME, MCM

Contrastive (대조):

"같은 것 가깝게, 다른 것 멀게"

→ 전체적 구조, 안정적 표현 학습

→ SCARF, ICL

- **InfoNCE** = Information Noise Contrastive Estimation, Contrastive Loss의 한 종류
- **Denoising Loss** = Reconstruction Loss와 본질적으로 같음(망가뜨리고 복원)
- **Loss** = "얼마나 못했나"의 수치 (낮을수록 좋음). 최소화가 최대화보다 수학적으로 편해서 "못한 정도"를 씀

6. JEPA (Joint-Embedding Predictive Architecture)

LeCun 제안. 임베딩 공간에서 예측하는 SSL 철학

세 가지 SSL 구조 비교:

- (a) Joint-Embedding (Contrastive): 같은 것 → 같은 임베딩. 증강 필요, Collapse 위험
- (b) Generative (Reconstruction): 임베딩 → 원본 복원. 비현실적 샘플 문제
- (c) JEPA: 한 임베딩 → 다른 임베딩 예측. 가장 깔끔

적용 분야: I-JEPA(이미지), V-JEPA(비디오), LeWorldModel(로봇), T-JEPA(테이블)

- 이미지/비디오/테이블: 있는 것을 가림(Mask)
- 로봇: 없는 미래를 진짜 예측
- 공통: "이걸로 저걸 예측" → 다 벡터로 만들어 임베딩 공간에서 처리

EMA = Exponential Moving Average, Target encoder를 천천히 업데이트해 Collapse 방지

7. Collapse 문제 (SSL의 핵심 난제)

정의: 모든 임베딩이 같은 벡터로 수렴 → Loss=0 되지만 아무것도 학습 안 됨(치트키)

모든 임베딩을 $[0,0,0]$ 으로 → 예측=정답= $[0,0,0]$ → Loss=0 (완벽해 보임)
→ 근데 피쳐 구분 전혀 안 됨

방지법

- Stop Gradient (Target encoder 역전파 차단) — T-JEPA
- Negative pairs (Contrastive) — SCARF, SubTab
- EMA (천천히 업데이트) — V-JEPA
- Redundancy reduction — Barlow Twins

취약도: T-JEPA > RaTab > SCARF/SubTab > VIME (정답 명확할수록/Negative pair 있을수록 Collapse 적음)

8. Transferable Representations (전이 가능한 표현)

목표: 한 번 배운 걸 레이블 적은 작업·다른 테이블에 재사용

방법	핵심 아이디어
STUNT (2023)	컬럼 선택 + K-means 클러스터링 → 가짜 레이블 생성. Few-shot 특화
TransTab (2022)	컬럼 이름을 텍스트 임베딩 → 다른 테이블도 같은 공간에 표현
CARTE (2024)	행을 star-shaped 그래프로 변환 + 외부 지식(Wikipedia 등) 통합

핵심 인사이트: 텍스트는 벡터화가 쉬움 → 컬럼 이름을 텍스트로 임베딩하면 "나이"와 "age"가 비슷한 벡터 → 다른 구조 테이블도 전이 가능

용어

- Cross-table setting: 완전히 다른 컬럼 구조의 테이블에 적용
- Few-shot: 레이블 몇 개(예: 1개)만으로 적응
- Zero-shot: fine-tuning 없이 바로 예측 (틀릴 확률 높지만 레이블 0개일 때 유일한 선택)
- Fine-tuning: 사전학습 모델을 특정 작업에 맞게 조금 더 학습 (의대 → 전공의 비유)

STUNT 결과: #shot=1 극한 상황에서 지도학습/일반 SSL은 실패, STUNT 압도적(적응 능력 자체를 학습해서)

9. Anomaly Detection (이상 탐지)

핵심: 정상 데이터만 학습 → 벗어난 것을 이상으로 탐지 (이상 레이블 불필요, 추가 학습 없음)

왜 정상만 학습하나: 비정상은 드물고, 종류가 무한하고, 새로운 유형은 미리 알 수 없음 (label-scarce는 결과일 뿐, 본질은 "비정상은 open-ended")

두 관점

Reconstruction-based: 정상은 부분정보로 복원 가능 → 복원 오차 = 이상 점수
Representation-based: 정상은 정상 공간에 뭉침 → 정상 영역과의 거리 = 이상 점수

방법	"정상"의 정의 (가정)	이상 점수
ICL	피처 부분집합 간 강한 내부 의존성	Contrastive loss
MCM	마스킹된 문맥으로 값 복원 가능 (학습 가능한 마스크)	복원 오차
NPT-AD	피처 간 + 샘플 간 의존성 둘 다 (NPT 구조)	복원 오차 (훈련 데이터 참조)
Disent-AD	겹치지 않는 두 그룹으로 나뉘고 각각 복원 가능 (Two-head Attention)	복원 오차
DRL	직교 기저벡터의 가중합으로 분해 가능	분해 오차

핵심 메시지: "정상이란 무엇인가"에 대한 가정 선택 = Inductive bias와 같은 개념

세부

- ICL(Internal Contrastive): 같은 샘플 안에서 일부 피처 ↔ 나머지 매칭 (외부 샘플 불필요)
- MCM: VIME 개선판. 마스크를 랜덤이 아닌 **학습**으로 발견(Mask Generator도 역전파로 학습), 여러 마스크로 다양한 패턴
- NPT-AD: MCM + NPT(행+열 Attention), 예측 시 훈련 데이터 참조(TabR처럼)
- Disent-AD: ICL과 비슷하지만 랜덤이 아닌 **의미있는 그룹**을 Attention으로 신중히 나눔
- DRL: 정상 = 기저벡터(레고 블록)로 조립 가능, 이상 = 조립 안 됨

10. 구조/계산 관련 용어 복습

Attention

- Q(Query, 찾는 것) / K(Key, 가진 정보) / V(Value, 실제 내용)
- $Q \times K$ = 유사도 → softmax → 가중치 → $\times V$ = 출력
- Head** = Attention 한 번 수행하는 단위. Multi-Head = 여러 관점 동시에

- Self-Attention(같은 입력 내부) vs Cross-Attention(다른 입력끼리)

MLP vs Attention 진짜 차이

MLP: 가중치 고정 (모든 샘플에 같은 가중치), 관계를 암묵적으로 파악
 Attention: 가중치 동적 (샘플마다 다름), 관계를 명시적으로 계산
 → 둘 다 역전파로 학습

역전파 핵심 (복습)

$\partial E / \partial w = \partial E / \partial a \times$ 이전층 출력값 → 이 층 가중치 업데이트용
 $\partial E / \partial a_{prev} = \partial E / \partial a \times$ 이 층 가중치 → 앞층 전달용
 (곱셈 미분 = 상대방이 남음)
 $\partial E / \partial w3 =$ "w3를 조금 바꾸면 오차가 얼마나 변하나" = gradient

CNN = 이미지용. "가까운 픽셀끼리 관련있다" 가정 → 테이블엔 안 맞음(컬럼 순서 무의미)

11. 큰 그림 / 철학적 결론

역전파의 한계

"Loss만 줄여라" = 단순한 목표
 → gradient descent가 최단 경로만 찾음
 → 정답 맞추는 최소한만 학습 (족보 외우기)

JEPA/SSL의 시도:
 → Loss를 더 어렵게 설계
 → "지름길 없이 진짜 이해해야만 풀리게"
 → 개념 이해하기 (범용성)

- 역전파(1986) 자체를 대체하면 노벨상감. 아직 아무도 못 만듦
- Hinton, LeCun, Bengio가 역전파로 튜링상, 근데 지금은 본인들이 한계 지적
- 하드웨어(계산량)로 해결 안 되는 소프트웨어 난제: Collapse, 추론 능력, 데이터 효율, 일반화

핵심 통찰

- 테이블의 모든 컬럼이 같은 주제(사람/거래/제품) 공유 → 자연스러운 연관관계 존재 → 이게 테이블 ML이 작동하는 근본 이유
- DB 설계는 컬럼 독립(정규화) 지향, ML은 연관관계 풍부할수록 좋음 → 다른 기준
- 벡터화 = 세상 모든 것을 숫자로 번역 → 번역 가능한 건 AI가, 불가능한 건(경험 못한 것) 아직 인간의 영역

최종 결론 (모든 챕터 공통)

"There is still no universal solution"

- 데이터 특성에 맞는 Inductive bias(가정) 선택이 핵심
- 데이터 부족 + 범용성 욕심 = 계산량 폭발
- 다음 방향: LLM 통합 (컬럼 이름 의미 이해가 핵심 열쇠)

12. 한눈 요약 (30초 복습용)

SSL: VIME→SCARF→SubTab→SAINT→RaTab→T-JEPA
(입력 오염 → 임베딩 예측으로 진화, Collapse가 난제)

Transfer: STUNT(few-shot)→TransTab(컬럼이름)→CARTE(외부지식)
(텍스트 임베딩이 전이의 열쇠)

Anomaly: ICL/MCM/NPT-AD/Disent-AD/DRL
(정상만 학습, "정상이란?"의 가정만 다름)

관통 원리: 다 벡터로 만들어 → 같은 공간에서 유사도/복원/예측
역전파가 기반, Loss 설계로 "진짜 이해" 유도